

## Lista 2 - Monte Carlo

AUTHORS

Andreia Queiroz Correia Dummar (222103912) ✉

Fernando da Silva Costa (232102946) ✉

Roberto Jorge Dummar Filho (232103587) ✉

### 1) Geração de Números Aleatórios

a. O método Inverse Transform - Exercício 3.3 do livro da Rizzo.

3.2 The Pareto( $a, b$ ) distribution has cdf

$$F(x) = 1 - \left(\frac{b}{x}\right)^a, x \geq b \geq 0, a \geq 0$$

Derive the probability inverse transformation  $F^{-1}(U)$  and use the inverse transform method to simulate a random sample from the Pareto(2, 2) distribution. Graph the density histogram of the sample with the Pareto(2, 2) density superimposed for comparison.

#### Resposta

Para cálculo da transformação inversa, temos que:

$$u = F(x) = 1 - \left(\frac{b}{x}\right)^a \Rightarrow 1 - u = \left(\frac{b}{x}\right)^a \Rightarrow (1 - u)^{\frac{1}{a}} = \frac{b}{x} \Rightarrow x = \frac{b}{(1 - u)^{\frac{1}{a}}} \Rightarrow F_x^{-1}(u) = b * (1 - u)^{\frac{-1}{a}}$$

Como explicado no Exemplo 3.3 (p.51),  $U$  e  $1 - U$  possuem a mesma distribuição  $Uniform(0, 1)$ , logo é mais simples utilizar  $b * (u)^{\frac{-1}{a}}$ .

Por se tratar de função de distribuição acumulada, é necessária derivá-la para encontrar a função densidade de probabilidade, logo:

$$F(x) = 1 - \left(\frac{b}{x}\right)^a, x \geq b \geq 0, a \geq 0$$

$$f(x) = F'(x) = 0 - (a) * (b^a * (-1) * x^{-a-1}) \Rightarrow a * b^a * x^{-(a+1)}, x \geq b$$


```
set.seed(1)
# Valores iniciais dados pelo problema
a <- 2
b <- 2
n <- 2000
u <- runif(n)
x <- b * (u)^(-1/a)
print(summary(x))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
2.000	2.303	2.880	4.024	4.075	81.294

```
hist(x, breaks = 100, prob = TRUE, col = 'lightgreen'
     , main = "Histograma de Amostra Simulada com Dens. Teórica Pareto(2, 2)"
     , xlab = 'x', ylab = 'Densidade')
y <- sort(x)
```

```
fy <- a * b^a * y^(-(a + 1))
lines (y, fy, col = 'red', lwd = 1)
```

### Histograma de Amostra Simulada com Dens. Teórica Pareto(2, 2)



b. O método Acceptance-Rejection - Exercício 3.7 do livro da Rizzo. (Exemplo 3.7 faz isso para Beta(2,2). Para simplificar vocês podem resolver a questão somente para  $\alpha$  e  $\beta$  maiores que 1.)

3.7 Write a function to generate a random sample of size  $n$  from the Beta( $a$ ,  $b$ ) distribution by the acceptance-rejection method. Generate a random sample of size 1000 from the Beta(3,2) distribution. Graph the histogram of the sample with the theoretical Beta(3,2) density superimposed.

#### Resposta

Vamos calcular a função densidade de probabilidade (PDF) para a distribuição Beta com parâmetros  $\alpha = 3$  e  $\beta = 2$ .

#### Definição Geral da PDF da Distribuição Beta

A função densidade de probabilidade (PDF) da distribuição Beta é dada por:

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}$$

onde  $B(\alpha, \beta)$  é a função beta:  $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ .

Para  $\alpha = 3$  e  $\beta = 2$ , a PDF se torna:

$$f(x; 3, 2) = \frac{x^{3-1}(1-x)^{2-1}}{B(3, 2)} = \frac{x^2(1-x)}{B(3, 2)}$$

Cálculo da Função Beta  $B(3, 2)$

A função beta para  $\alpha = 3$  e  $\beta = 2$  é:  $B(3, 2) = \frac{\Gamma(3)\Gamma(2)}{\Gamma(3+2)}$

Usando as propriedades da função gama:  $\Gamma(n) = (n - 1)!$ , então,  $\Gamma(3) = 2! = 2$ ,  $\Gamma(2) = 1! = 1$ ,  $\Gamma(5) = 4! = 24$

Portanto,  $B(3, 2) = \frac{2! \cdot 1!}{4!} = \frac{2 \cdot 1}{24} = \frac{2}{24} = \frac{1}{12}$

Substituindo  $B(3, 2) = \frac{1}{12}$  na expressão da PDF:

$$f(x; 3, 2) = \frac{x^2(1-x)}{\frac{1}{12}} = x^2(1-x) \cdot 12 = 12x^2(1-x)$$


No exercício, para os valores de  $\alpha = 3$  e  $\beta = 2$ , temos uma distribuição unimodal com um pico, assimétrica e levemente inclinada para a direita.

```
function_Beta <- function(n, a, b)
{
  k <- 0
  y <- numeric(n)
  count <- 0
  while (k < n)
  {
    u <- runif(1)
    x <- runif(1)
    if (x^(a - 1) * (1 - x)^(b - 1) > u)
    {
      k <- k + 1
      y[k] <- x
    }
    count <- count + 1
  }
  print(paste("Quantidade de iterações: ", count))
  return(y)
}

y <- function_Beta(1000, a = 3, b = 2)
```

[1] "Quantidade de iterações: 11880"

```
hist(y, breaks = 50, prob = TRUE, ylim = c(0, 2.5), col='lightgreen')
z <- seq(0, 1, .01)
f.z <- 12 * z^2 * (1-z)
lines(z, f.z, col = 'red', lwd=2)
```



## 2) Integração por Monte Carlo

a. Exercício 5.3 do livro da Rizzo. (Opcional: gera da exponencial truncada ao intervalo  $[0;0.5]$  e compara a variância.)

Compute a Monte Carlo estimate  $\hat{\theta}$  of

$$\theta = \int_0^{0.5} e^{-x} dx$$

by sampling from  $Uniform(0, 0.5)$ , and estimate the variance of  $\hat{\theta}$ . Find another Monte Carlo estimator  $\hat{\theta}^*$  by sampling from the exponential distribution. Which of the variances (of  $\hat{\theta}$  and  $\hat{\theta}^*$ ) is smaller, and why?

### Resposta

O valor exato da integral é dado por:

$$\theta = -e^{-0.5} - (-e^0) = 1 - e^{-0.5} = 1 - 0.606531 = 0.393469$$

O estimador de Monte Carlo é dado pela expressão:

$$\hat{\theta} = (b - a) \int_a^b g(x) dx = \frac{1}{2} \left( \frac{1}{m} \sum_{i=1}^m e^{-u} \right),$$

sendo que  $u$  é gerado a partir de uma distribuição  $Uniforme(0, 0.5)$ .

```
n <- 20000
# Geração da distribuição uniforme entre os intervalos 0 e 0.5
u <- runif(n, 0, 0.5)
theta <- 0.5 * mean(exp(-u))
theta
```

```
[1] 0.393242
```

```
# Para cada 20.000 amostras da distribuição uniforme no intervalo [0, 0.5], vamos
# calcular o estimador de Monte Carlo usando a função 0.5 * exp(-u), fazendo isso
# 2.000 vezes
estimator <- replicate(2000, expr = {
  u <- runif(n, 0, 0.5)
  theta <- 0.5 * mean(exp(-u))
  theta
})
print(paste("Média do estimador: ", mean(estimator)))
```

```
[1] "Média do estimador: 0.39347051705846"
```

```
print(paste("Variância do estimador: ", var(estimator)))
```

```
[1] "Variância do estimador: 1.59552490493912e-07"
```

```
print(paste("DP do estimador: ", sd(estimator)))
```

```
[1] "DP do estimador: 0.000399440221427327"
```

Para estimarmos a variância de  $\hat{\theta}^*$ , vamos utilizar a seguinte expressão:

$$\hat{\theta}^* = \frac{1}{m} \sum_{i=1}^m I(v < 0.5)$$

, sendo  $v$  gerado a partir de uma distribuição *Exponential*(1).

```
n <- 20000
v <- rexp(n, 1)
theta <- mean(v <= 0.5)
print(theta)
```

```
[1] 0.3918
```

```
estimator_1 <- replicate(2000, expr = {
  v <- rexp(n, 1)
  theta <- mean(v <= 0.5)
  theta
})
print(paste("Média do estimador", mean(estimator_1)))
```

```
[1] "Média do estimador 0.393552925"
```

```
print(paste("Variância do estimador: ", var(estimator_1)))
```

```
[1] "Variância do estimador: 1.19860106997249e-05"
```

```
print(paste("Desvio-padrão do estimador: ", sd(estimator_1)))
```

```
[1] "Desvio-padrão do estimador: 0.00346208184474672"
```

```
print(paste("Razão entre os estimadores: ", var(estimator)/var(estimator_1)))
```

```
[1] "Razão entre os estimadores: 0.0133115591576749"
```

A variância do estimador  $\hat{\theta}$  (baseado na amostragem uniforme) é maior do que a variância do estimador  $\hat{\theta}^*$  (baseado na amostragem exponencial) porque a transformação usada na amostragem exponencial pode reduzir a variabilidade dos valores amostrados, uma vez que é melhor ajustada à forma da função de densidade  $e^{-x}$ .

Assim, o estimador  $\hat{\theta}^*$  terá uma variância menor devido à melhor adequação da amostragem à distribuição exponencial.

b. Variáveis Antitéticas: Exercício 5.10 do livro da Rizzo. (Opcional: Trocar esse exercício para 5.9, mas saiba que a função não é monotônica [pode quebrar em pedaços monotônicos] e o limite superior é infinito [precisa fazer alguma transformação de variáveis  $x \rightarrow 1/x$  funcionaria])

Use Monte Carlo integration with antithetic variables to estimate

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx$$

and find the approximate reduction in variance as a percentage of the variance without variance reduction.

### Resposta

O uso de variáveis antiéticas ajudam a reduzir a variabilidade de um método e estimação.

Como regra geral, temos que:

$$Var\left(\frac{U_1 + U_2}{2}\right) = \frac{1}{4} * (Var(U_1) + Var(U_2) + 2 * Cov(U_1, U_2))$$

sendo que a variância de  $\frac{(U_1+U_2)}{2}$  é menor se  $U_1$  e  $U_2$  são negativamente correlacionadas do que quando as variáveis são independentes.

Neste caso, iremos gerar uma distribuição  $Uniforme(0, 1)$  e aplicar o estimador de Monte Carlo para o valor de  $u$ .

Ainda, para calcularmos com o uso de variáveis antiéticas, iremos aplicar a expressão abaixo:

$$\hat{\theta} = \frac{1}{m} \left\{ Y_1 + Y'_1 + Y_2 + Y'_2 + \dots + Y_{m/2} + Y'_{m/2} \right\}$$

```
set.seed(10)
m <- 20000
monte_carlo <- replicate(2000, expr =
{
  u <- runif(m)
```

```

        mean(exp(-u)/(1 + u^2))
      }
    )
  set.seed(10)
  anti_ethic <- replicate(2000, expr =
    { u <- runif(m/2)
      x1 <- exp(-u)/(1 + u^2)
      x2 <- exp(-(1-u))/(1 + ((1-u)^2))
      mean(c(x1, x2))
    }
  )

  print(c(mean(monte_carlo), var(monte_carlo)))

```

```
[1] 5.247396e-01 3.019848e-06
```

```
print(c(mean(anti_ethic), var(anti_ethic)))
```

```
[1] 5.247863e-01 1.180597e-07
```

```

approx_reduction = 100 * (var(monte_carlo) - var(anti_ethic)) / var(monte_carlo)
print(paste(round(approx_reduction,4), "%"))

```

```
[1] "96.0905 %"
```

A redução da variância entre o uso de Monte Carlo padrão e o uso de Monte Carlo com variáveis antiéticas foi de 96,09%.

c. Importance Sampling - Exercício 5.14 do livro da Rizzo.

Obtain a Monte Carlo estimate of

$$\int_1^{\infty} \frac{x^2}{\sqrt{2\pi}} e^{-x^2/2} dx$$

by importance sampling.

### Resposta

Para a análise, foram utilizadas com as distribuições:

1. Distribuição  $x^2$  com 1 grau de liberdade
2. Distribuição  $\Gamma$  (Gamma) com parâmetros  $\alpha = \frac{3}{2}$  e  $\beta = 2$
3. Distribuição exponencial
4. Distribuição Cauchy (com localização 2 e escala 1)

```

set.seed(1)
n <- 20000
imp_sampl_1 <- replicate(2000, expr =
{
  x <- sqrt(rchisq(n, 1)) + 1
  f <- 2 * dnorm(x, 1)
  g <- x^2 * exp(-x^2/2)/sqrt(2 * pi)
  mean(g/f)
}
)

```

```

set.seed(1)
imp_sampl_2 <- replicate(2000, expr =
  {
    x <- rgamma(n, 3/2, 2) + 1
    f <- dgamma(x - 1, 3/2, 2)
    g <- x^2 * exp(-x^2/2)/sqrt(2 * pi)
    mean (g/f)
  }
)
set.seed(1)
imp_sampl_3 <- replicate(2000, expr =
  {
    x <- rexp(n, 1)
    f <- dexp(x, 1)
    g <- x^2 * exp(-x^2/2)/sqrt(2 * pi)
    mean (g/f)
  }
)
set.seed(1)
imp_sampl_4 <- replicate(2000, expr =
  {
    x <- rcauchy(n, 2, 1)
    f <- dcauchy(x, 2, 1)
    g <- x^2 * exp(-x^2/2)/sqrt(2 * pi)
    mean (g/f)
  }
)

print(c(mean(imp_sampl_1), mean(imp_sampl_2), mean(imp_sampl_3), mean(imp_sampl_4)))

```

```
[1] 0.4006161 0.4006423 0.4999949 1.0002580
```

```
print(c(var(imp_sampl_1), var(imp_sampl_2), var(imp_sampl_3), var(imp_sampl_4)))
```

```
[1] 9.727324e-08 6.082952e-07 1.465524e-05 2.061787e-04
```

```
print(var(imp_sampl_1)/var(imp_sampl_2))
```

```
[1] 0.1599112
```

No caso em tela, A média das estimativas estão próximas, pois todas estão estimando a mesma integral.

A 1ª função importância produz um estimador mais eficiente, com maior precisão e menor variabilidade que as demais funções uma vez que possui a menor variância.

d. Stratified Importance Sampling - Exercício 5.15 do livro da Rizzo. (Não esquece de usar os quantís da função importância para definir os intervalos.)

*Obtain the stratified importance sampling estimate in Example 5.13 and compare it with the result of Example 5.10.*

### Resposta

O exemplo 5.13 traz a seguinte integral:



$$\int_0^1 \frac{e^{-x}}{1+x^2} dx$$

com a função importância dada por:

$$f(x) = \frac{e^{-x}}{1-e^{-1}}, 0 < x < 1,$$

nos cinco subintervalos:  $(j/5, (j+1)/5), j = 0, 1, \dots, 4$ .

As variáveis no  $j^{th}$  subintervalo são geradas a partir da densidade:

$$\frac{5e^{-x}}{1-e^{-1}}, \quad \frac{j-1}{5} < x < \frac{j}{5}.$$

Para encontrar a transformação inversa usada no código, considere a função de importância dada por:

$$f(x) = \frac{e^{-x}}{1-e^{-1}} \quad \text{para } 0 < x < 1$$

Primeiro, encontramos a função de distribuição acumulada (CDF) da função de importância (  $f(x)$  ):

$$F(x) = \int_0^x \frac{e^{-t}}{1-e^{-1}} dt$$

Integrando, obtemos:

$$F(x) = \left[ \frac{-e^{-t}}{1-e^{-1}} \right]_0^x = \frac{1-e^{-x}}{1-e^{-1}}$$

Para obter a transformação inversa, resolvemos (  $F(x) = u$  ) para (  $x$  ):

$$\begin{aligned} u &= \frac{1-e^{-x}}{1-e^{-1}} \Rightarrow u(1-e^{-1}) = 1-e^{-x} \Rightarrow e^{-x} = 1-u(1-e^{-1}) \Rightarrow \\ &\Rightarrow \ln(e^{-x}) = \ln(1-u(1-e^{-1})) \Rightarrow x = -\ln(1-u(1-e^{-1})) \end{aligned}$$

que é a transformação inversa da função de distribuição acumulada (CDF) da distribuição de importância

$$f(x) = \frac{e^{-x}}{1-e^{-1}}$$

```
set.seed(1)
M <- 20000
k <- 5
m <- M/k
si_stratified <- numeric(k)
v_stratified <- numeric(k)
g <- function(x) exp(-x)/(1+x^2)
f <- function(x) ((k * exp(-x))/(1-exp(-1)))

for(j in 1:k) {
  u <- runif(m, (j-1)/k, j/k)
  x <- -log(1 - (1-exp(-1)) * u)
  gf <- g(x)/f(x)
```

```

    si_stratified[j] <- mean(gf)
    v_stratified[j] <- var(gf)
  }

  print(paste("A soma da média dos estratos para estimativa da integral é: ", sum(si_stra

```

```
[1] "A soma da média dos estratos para estimativa da integral é: 0.524763642375128"
```

```
  print(paste("A média da variância dos estratos é: ", mean(v_stratified)))
```

```
[1] "A média da variância dos estratos é: 1.74807187879508e-05"
```

```
  print(sqrt(mean(v_stratified)))
```

```
[1] 0.004180995
```

No caso do exemplo 5.10, se não fosse usada a estratificação, os valores seriam:

```

set.seed(1)
M <- 20000
si <- 0
v <- 0
g <- function(x) exp(-x)/(1 + x^2)
f <- function(x) (exp(-x)/(1 - exp(-1)))
u <- runif(M)
x <- -log(1 - (1 - exp(-1)) * u)
gf <- g(x)/f(x)

si_n_stratified <- mean(gf)
v_n_stratified <- var(gf)

print(si_n_stratified)

```

```
[1] 0.5245328
```

```
  print(v_n_stratified)
```

```
[1] 0.009477452
```

```
  print(sqrt(v_n_stratified))
```

```
[1] 0.0973522
```

```
  print((v_n_stratified - mean(v_stratified))/v_n_stratified)
```

```
[1] 0.9981555
```

No exemplo calculado, a variância por amostragem estratificada foi reduzida para 99,82% do valor da variância por amostragem não estratificada.

### 3) Inferência com Monte Carlo

a. MSE (EQM): Exercício 6.1 do livro da Rizzo. (aproveite os códigos para a Normal com contaminação)

*Estimate the MSE of the level  $k$  trimmed means for random samples of size 20 generated from a standard Cauchy distribution. (The target parameter  $\theta$  is the center or median; the expected value does not exist.) Summarize the estimates of MSE in a table for  $k = 1, 2, \dots, 9$ .*

#### Resposta:

A distribuição de Cauchy é uma distribuição contínua com densidade de probabilidade dada por:

$$f(x; x_0, \gamma) = \frac{1}{\pi\gamma \left[ 1 + \left( \frac{x-x_0}{\gamma} \right)^2 \right]}$$

Para a distribuição de Cauchy padrão, temos ( $x_0 = 0$ ) e ( $\gamma = 1$ ):

$$f(x) = \frac{1}{\pi(1+x^2)}$$

Trimmed mean (média podada) é uma média calculada excluindo os valores extremos de uma amostra. Para uma amostra ordenada  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ :

- O nível de podagem  $k$  indica que os  $k$  menores e os  $k$  maiores valores são excluídos.
- A média podada é então calculada sobre os  $n - 2k$  valores restantes.

O erro quadrático médio (MSE) é uma medida de precisão de um estimador. Para um estimador  $\hat{\theta}$  do parâmetro  $\theta$ :

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$$

```
set.seed(1)
n <- 20
K <- n/2 - 1
m <- 1000
mse <- matrix(0, n/2, 2)
trimmed.mse <- function(n, m, k)
{
  tmean <- numeric(m)
  for (i in 1:m)
  {
    x <- sort(rcauchy(n))
    tmean[i] <- sum(x[(k + 1):(n - k)])/(n - 2 * k)
  }
  mse.est <- mean(tmean^2)
  se.mse <- sqrt(mean((tmean - mean(tmean))^2))/sqrt(m)
  return(c(mse.est, se.mse))
}

for (k in 0:K)
{
  mse[k + 1, 1:2] <- trimmed.mse(n = n, m = m, k = k)
}
```

```
mse <- as.data.frame(cbind(0:K, mse))
names(mse) <- c("k", "média podada", "erro padrão")
print(mse)
```

	k	média podada	erro padrão
1	0	1766.9212480	1.32920584
2	1	1.9158594	0.04374635
3	2	0.3245856	0.01795765
4	3	0.2503728	0.01579560
5	4	0.1752799	0.01322104
6	5	0.1476811	0.01213569
7	6	0.1447897	0.01203215
8	7	0.1174757	0.01083862
9	8	0.1284601	0.01133352
10	9	0.1400133	0.01179556

A tabela de resultados mostra como o MSE da média podada varia com diferentes níveis de podagem  $k$ . Conforme o nível de  $k$  aumenta, excluem-se os valores mais extremos, melhorando a precisão do estimador, reduzindo o erro quadrático médio. No caso, a podagem ajuda a reduzir o efeito dos outliers na distribuição de Cauchy, que afetam mais significativamente a média.

Entretanto, o MSE e o erro padrão atingem seus menores valores não no máximo valor de  $k$ , mas quando ele é igual a 7.

#### b. Poder de testes: Exercício 6.3 do livro da Rizzo. (aproveite os códigos do Exemplo 6.9)

*Plot the power curves for the t-test in Example 6.9 for sample sizes 10, 20, 30, 40, and 50, but omit the standard error bars. Plot the curves on the same graph, each in a different color or different line type, and include a legend. Comment on the relation between power and sample size.*

#### Resposta


```
N <- c(10, 20, 30, 40, 50)
m <- 1000
mu0 <- 500
sigma <- 100
mu <- c(seq(450, 650, 10)) #alternatives
M <- length(mu)
power <- matrix(0, M, 5)
for (j in 1:5)
{
  n <- N[j]
  for (i in 1:M)
  {
    mu1 <- mu[i]
    pvalues <- replicate(m, expr =
    {
      #simulate under alternative mu1
      x <- rnorm(n, mean = mu1, sd = sigma)
      ttest <- t.test(x, alternative = "greater", mu = mu0)
      ttest$p.value
    })
    power[i, j] <- mean(pvalues <= .05)
  }
}
```

```

plot(mu, power[, 1], type = "l", ylim = range(power), xlab = bquote(mu), ylab = "Poder
abline(v = mu0, lty = 3)
abline(h = 0.05, lty = 3)
for (j in 2:5)
{
  lines(mu, power[, j], col = j)
}

legend("bottomright", inset = 0.02, legend = N, col = 1:5, lty = 1)

```



Quando o tamanho da amostra aumenta, a precisão das estimativas de parâmetros também aumenta. A média amostral se aproxima da verdadeira média populacional  $\mu_0$ , diminuindo a variabilidade da média amostral. Isso resulta em um maior poder estatístico, permitindo detectar diferenças menores entre a média amostral e  $\mu_0$ . Portanto, quanto mais se aumentam as amostras, mais a curva do poder estatístico se aproxima de  $\mu_0$ , indicando uma maior capacidade de detectar desvios da hipótese nula.

c. Níveis de confiança: Exercício 6.4 ou 6.5 do livro da Rizzo

6.4 Suppose that  $X_1, \dots, X_n$  are a random sample from a lognormal distribution with unknown parameters. Construct a 95% confidence interval for the parameter  $\mu$ . Use a Monte Carlo method to obtain an empirical estimate of the confidence level.

### Resposta

Iremos gerar uma amostra de tamanho 50 a partir de uma distribuição lognormal padrão (com média logarítmica  $\mu = 0$  e desvio padrão logarítmico  $\sigma = 1$ ).

O intervalo de confiança é calculado utilizando-se a fórmula:

$$\left( \bar{y} - 1.96 \cdot \frac{s_y}{\sqrt{30}}, \bar{y} + 1.96 \cdot \frac{s_y}{\sqrt{30}} \right)$$

```
set.seed(1)
n <- 50
confid_interv <- replicate(20000, expr =
{
  x <- rlnorm(n, 0, 1)
  y <- log(x)
  ybar <- mean(y)
  se <- sd(y)/sqrt(n)
  ybar + se * qnorm(c(0.025, 0.975))
})
L_confid_interv <- confid_interv[1, ]
U_confid_interv <- confid_interv[2, ]

print(paste("Quantidade de ICs que contém o valor da média logarítmica: ", sum(L_confid_interv < 0 && U_confid_interv > 0)))
```

```
[1] "Quantidade de ICs que contém o valor da média logarítmica: 18904"
```

```
print(paste("Proporção de ICs que contém o verdadeiro valor de mi: ", 100 * mean(L_confid_interv < 0 && U_confid_interv > 0)))
```

```
[1] "Proporção de ICs que contém o verdadeiro valor de mi: 94.52 %"
```

Ao usarmos a simulação Monte Carlo para validar a construção de intervalos de confiança (IC) para a média logarítmica  $\mu$  de uma distribuição lognormal, do total de 20.000 IC, temos 18.904 IC que contém o valor da média logarítmica ( $\mu = 0$  para a distribuição lognormal padrão).

Ainda, temos que a proporção de IC que contém o valor 0, pela simulação, foi de 94,52%, um valor muito próximo de 95%.